

CS:GO DEATH PREDICTION

Previsão de eventos de morte em partidas profissionais de CS:GO utilizando Machine Learning



Breno de Pádua
222500



César Augusto
222909



Darlan Henrique
211926



Lucas Nascimento
223324

VISÃO GERAL DO DATASET

Análise completa de dados de partidas profissionais de CS:GO



5.317

Horas de CS:GO Profissional

Tempo total de gameplay analisado



824

Partidas Analisadas

Partidas profissionais incluídas



7

Mapas Analisados

Dust2, Mirage, Inferno e outros



40

Colunas de Dados

Features por registro da partida



Qualidade dos Dados

O dataset contém mais de 19 milhões de linhas, com 146 mil casos de sucesso e 162 mil casos de falha após o pré-processamento.

TRATAMENTO INICIAL & PRÉ-PROCESSAMENTO

Processo de transformação e otimização dos dados



Dados Originais

6.6GB

Formato Parquet



Compressão

2.3GB

Redução de 65%



Filtragem

9.6MB

Dataset final



Linhas

19M

~19.000.000 linhas



Casos de Sucesso

146.426



Casos de Falha

162.191



Mapas Analisados

7



Sucesso: Sobreviveu e matou inimigos (aumento da kills_from_avg) **Falha:** Morte

TRATAMENTO DOS MAPAS

Remoção de mapas inválidos e manutenção dos 7 mapas principais para análise

 Média Geral

Rounds por partida

25.75

Critério aplicado

Foram removidos registros inconsistentes e não representativos, mantendo apenas os mapas principaise e corretos para análise.

 Média de Rounds por Mapa

Mapa	Média de Rounds
Overpass	26.58
Dust2	26.03
Inferno	25.81
Ancient	25.72
Mirage	25.49
Nuke	25.28
Vertigo	25.19

 Distribuição por Mapa

Mapa	Total	%
z	3	0.36%
Ancient	78	9.39%
Dust	1	0.12%
Dust2	116	13.96%
Inferno	147	17.69%
Mirage	138	16.61%
Nuke	143	17.21%
Overpass	113	13.60%
p1	1	0.12%
p2	2	0.24%
Vertigo	89	10.71%

DISTRIBUIÇÃO DE AÇÕES

Análise estatística de eventos e comportamento dos jogadores durante as partidas

 Estado do Jogador

isAlive	Total	%
0	4.9M	25.6%
1	14.2M	74.4%

 Jogadores Scoped

isScoped	Total	%
0	18.2M	95.2%
1	0.9M	4.8%

 Tempo da Rodada

Round principal

115s

Tempo da bomba

40s

Freeze Time

15-20s

Tempo total

175s

 Uso de Capacete

hasHelmet	Total	%
0	9.1M	47.4%
1	10.1M	52.6%

 Efeito de Flashbang

isBlinded	Total	%
0	18.6M	97.2%
1	0.5M	2.8%

DISTRIBUIÇÃO DE MOVIMENTO

Análise estatística dos estados de movimentação e posicionamento dos jogadores

Jogadores Agachados

isDucking	Total	%
0	17.7M	92.3%
1	1.5M	7.7%

Jogadores Andando

isWalking	Total	%
0	14.9M	77.8%
1	4.2M	22.2%

Jogadores Parados

isStanding	Total	%
0	2.2M	11.3%
1	17.0M	88.7%

Jogadores no Ar

isAirborne	Total	%
0	13.3M	69.8%
1	5.8M	30.2%

ANÁLISE TEMPORAL

Distribuição de mortes e distância entre jogadores ao longo da rodada

💡 Insight Principal

As eliminações aumentam entre os **40 e 30 segundos finais** da rodada.

Boxplot — Distância do Inimigo Mais Próximo



💓 Jogadores Vivos

isAlive	Total	%
0	4.9M	25.6%
1	14.2M	74.4%

👥 Jogadores Vivos no Time

Jogadores	Total	%
0	620k	3.2%
1	1.6M	8.3%
2	2.1M	10.9%
3	2.6M	13.8%
4	3.5M	18.1%
5	8.7M	45.7%

ANÁLISE DE COMBATE

Distribuição das armas que aparecem na mão dos jogadores durante as partidas

 Armas em Uso pelos Jogadores

Categoria	Total	%
Rifle de Assalto	5.6M	39.4%
Arma Corpo a Corpo	2.7M	19.1%
Utilitários	2.3M	16.2%
Pistola	1.8M	12.8%
Rifle de Precisão	1.4M	9.7%
SMG	394k	2.8%
Shotgun	13.4k	0.1%
Metralhadora	1.1k	0.01%

 Destaques

Arma mais frequente em uso

39.4%

Total aproximado de registros

14.2M

Os **rifles de assalto** aparecem como a categoria mais presente na mão dos jogadores. Isso indica maior frequência de uso dessa classe de arma ao longo das partidas, não necessariamente maior número de eliminações.

ANÁLISE DE COMBATE

Comparação entre cenários de sucesso e falha durante os conflitos

 Diferença entre Cenários

Feature	Sucesso	Falha	Diferença
hp_closest_enemy	77.0	85.0	-9.4%
total_hp_enemy	301.3	322.8	-6.7%
num_enemy_alive	3.53	3.62	-2.6%
num_team_alive	3.64	3.56	+2.3%
total_hp_team	324.8	304.5	+6.7%
distance_closest_enemy	145.0	110.1	+31.7%

 Insights

Maior diferença encontrada

+31.7%

Feature mais impactante

Distância

Os cenários de **sucesso** estão associados a uma distância maior do inimigo mais próximo, maior vida total da equipe e menor vida total dos inimigos. Já as **falhas** ocorrem mais próximas dos adversários e com inimigos em melhores condições de vida.

ANÁLISE DE COMBATE

Comparação entre estados associados a cenários de sucesso e morte



Success
Jogador vivo



Death
Morte do jogador

 Comparação de Estados do Jogador

Feature	Success	Death	Diferença Relativa
isScoped	0.593	0.470	+26.2%
hasHelmet	0.500	0.433	+15.5%
isAirborne	0.540	0.475	+13.6%
isWalking	0.520	0.470	+10.7%
isStanding	0.486	0.444	+9.4%
isDucking	0.455	0.482	-5.6%
isBlinded	0.405	0.485	-16.4%

 Insights

Maior variação positiva

+26.2%

Feature mais associada ao sucesso

Scoped

Estados como **isScoped**, **hasHelmet** e **isWalking** aparecem mais associados a cenários de sucesso, sugerindo melhor preparação e controle do jogador. Já **isBlinded** e **isDucking** aparecem mais ligados a cenários de morte.

ANÁLISE DE ECONOMIA

Comparação econômica entre cenários de sucesso e falha

 Diferença entre Cenários

Feature	Sucesso	Falha	Diferença Relativa
Valor de Equipamento Inimigo	14.696	16.768	-12.4%
Dinheiro	2.032	2.032	≈0.0%
Armadura	87.0	80.7	+7.8%
Valor de Equipamento do Jogador	4.513	4.098	+10.1%
Valor de Equipamento do Time	16.891	14.970	+12.8%

 Insights

Maior diferença positiva

+12.8%

Feature mais relevante

Economia do Time

Os cenários de **sucesso** estão associados a maior **valor de equipamento do time**, maior armadura e melhor equipamento individual. Já as **falhas** aparecem com maior valor de equipamento inimigo, indicando vantagem econômica adversária.

TREINAMENTO VS TESTE

Estratégia de separação e pipeline utilizado para treinamento do modelo

Proporção e Técnicas Utilizadas



Divisão **holdout** em **80% treino** e **20% teste isolado**.



Utilização de **TrainValidationSplit** para validação interna durante o treinamento.



Pipeline composto por **StringIndexer**, **VectorAssembler**, **StandardScaler** e **LogisticRegression**.



Ajuste de hiperparâmetros **regParam** e **elasticNetParam** durante o tuning.

Split

80/20

Valor influenciado pelo **TrainValidationSplit**

Insight

O uso do **TrainValidationSplit** permitiu validar múltiplas combinações de parâmetros durante o treinamento, reduzindo risco de overfitting e melhorando a capacidade de generalização.

Pipeline:

Indexação → Vetorização → Normalização → Modelo

RESULTADOS DA REGRESSÃO

Validação dos hiperparâmetros utilizando F1-Score

Melhor regParam

0.01

Melhor elasticNet

0.0

Melhor F1

0.6497

 Resultados do Tuning

regParam	elasticNetParam	F1-Score
0.001	0.0	0.6492
0.001	0.5	0.6496
0.001	1.0	0.6481
0.01	0.0	0.6497
0.01	0.5	0.6463
0.01	1.0	0.6430
0.1	0.0	0.6485
0.1	0.5	0.6347
0.1	1.0	0.3651

 Insight Principal

Os melhores resultados ocorreram com **elasticNet = 0**, indicando melhor adaptação da regularização Ridge para o dataset.

 Análise

Valores altos de regularização combinados com **elasticNet = 1.0** reduziram drasticamente o desempenho do modelo.

AVALIAÇÃO DO MODELO

Métricas finais e distribuição das predições da regressão logística

Métricas Gerais

Accuracy

0.6486

F1-Score

0.6483

AUC-ROC

0.7061

Distribuição das Predições

Resultado Real	Predição	Quantidade
0	0	22.112
0	1	10.386
1	0	11.277
1	1	17.876

Insight

O modelo apresentou **boa capacidade de separação**, atingindo AUC superior a 0.70 e F1-score equilibrado.

Melhor Métrica

0.7061

Análise

Os resultados indicam equilíbrio razoável entre **falsos positivos** e **falsos negativos**, sem viés extremo para uma única classe.

TOP 5 FEATURES

Features com maior impacto absoluto, considerando os coeficientes em módulo

Features Mais Relevantes

#	Feature	Coeficiente
1	hp	0.5217
2	total_hp_enemy	0.1913
3	hp_closest_enemy	0.1820
4	num_enemy_alive	0.1414
5	equipment_value_enemy	0.1198

Insight

As variáveis relacionadas à **vida**, **inimigos vivos** e **economia inimiga** foram as que mais impactaram o modelo em valor absoluto.

Maior Impacto

0.5217

Análise

A sobrevivência do jogador foi fortemente influenciada por **HP**, **quantidade de inimigos vivos** e **vantagem econômica adversária**.

TREINAMENTO X TESTE

Configuração utilizada para treinamento e validação da árvore de decisão

Proporção e Técnicas Utilizadas

 Divisão holdout em **80% treino** e **20% teste isolado**.

 Utilização de **TrainValidationSplit** com validação interna sobre o conjunto de treino.

 Pipeline utilizando **StringIndexer**, **VectorAssembler** e **DecisionTreeClassifier**.

 Ajuste do parâmetro **maxDepth** durante o processo de tuning.

Insight

Valor influenciado pelo
TrainValidationSplit

Divisão de Dados

80/20

Análise

O uso de **TrainValidationSplit** permitiu testar diferentes profundidades da árvore, buscando melhor resultado no conjunto de teste.

RESULTADOS DA ÁRVORE

Avaliação das profundidades testadas durante o tuning da árvore de decisão

Resultados do Tuning

Melhor maxDepth

12

Número de Nós

4953

Melhor F1

0.6549

maxDepth	F1-Score
5	0.6372
7	0.6419
9	0.6502
12	0.6549
15	0.6471

Insight

A profundidade **12** apresentou o melhor desempenho, equilibrando capacidade de aprendizado e generalização.

Melhor Resultado

0.6549

Análise

Profundidades muito pequenas limitaram o aprendizado, enquanto profundidades maiores começaram a apresentar sinais de **overfitting**.

AVALIAÇÃO DA ÁRVORE

Métricas finais e distribuição das predições da árvore de decisão

Métricas Gerais

Accuracy
0.6530

F1-Score
0.6532

AUC-ROC
0.5777

Distribuição das Predições

Resultado Real	Predição	Quantidade
0	0	21.328
0	1	11.170
1	0	10.225
1	1	18.928

Insight

A árvore apresentou **F1-Score competitivo**, mas capacidade de separação inferior em relação à regressão logística.

Melhor Métrica
0.6532

Análise

O modelo conseguiu manter equilíbrio entre acertos e erros, porém o **AUC-ROC reduzido** indica menor robustez na separação entre classes.

TOP 5 FEATURES

Features mais relevantes segundo a importância calculada pela árvore de decisão

Importância das Features

#	Feature	Importância
1	hp	0.2803
2	enemy_hp_in_range_1000	0.0884
3	equipmentValue	0.0791
4	enemy_hp_in_range_2000	0.0704
5	equipment_value_enemy	0.0653

Insight

A árvore priorizou fortemente variáveis relacionadas à **vida do jogador** e **HP dos inimigos próximos**.

Maior Importância

0.2803

Análise

As features ligadas à **vida** e **economia** dominaram as divisões da árvore, indicando forte impacto na tomada de decisão do modelo.

TREINAMENTO X TESTE

Configuração utilizada para treinamento e validação da rede neural

⚙️ Proporção e Técnicas Utilizadas

📊 Divisão holdout em **80% treino** e **20% teste isolado**.

🔄 Utilização de **CrossValidator** com **3 folds** sobre o conjunto de treino.

📋 Pipeline utilizando **StringIndexer**, **VectorAssembler**, **StandardScaler** e **MultilayerPerceptronClassifier**.

🧠 Arquitetura da rede definida em **44 → 64 → 32 → 2 neurônios**.

⚙️ Ajuste de **maxIter** e **stepSize** durante o tuning.

💡 Insight

A rede neural foi configurada para capturar relações **não lineares** entre as variáveis do jogo, utilizando múltiplas camadas ocultas.

Arquitetura

44 → 64 → 32 → 2

📊 Análise

O uso de **CrossValidator** permitiu avaliar diferentes combinações de hiperparâmetros, buscando maior capacidade de generalização do modelo.

RESULTADOS DA REDE NEURAL

Avaliação das combinações de hiperparâmetros utilizando validação cruzada

Resultados do Tuning

Melhor maxIter

200

Melhor stepSize

0.03

Melhor F1

0.6622

maxIter	stepSize	F1-Score
100	0.03	0.6578
100	0.10	0.6580
200	0.03	0.6622
200	0.10	0.6622

Insight

Os melhores resultados ocorreram utilizando **200 iterações**, indicando necessidade de maior convergência durante o treinamento.

Melhor Resultado

0.6622

Análise

As diferenças entre os parâmetros foram pequenas, mostrando estabilidade no treinamento da rede neural mesmo com diferentes valores de **stepSize**.

AVALIAÇÃO DA REDE NEURAL

Métricas finais e distribuição das predições da rede neural

Métricas Gerais

Accuracy

0.6633

F1-Score

0.6628

AUC-ROC

0.7244

Distribuição das Predições

Resultado Real	Predição	Quantidade
0	0	22.664
0	1	9.834
1	0	10.926
1	1	18.227

Insight

A rede neural apresentou o **melhor desempenho geral** entre os modelos testados, principalmente na separação entre classes.

Melhor Métrica

0.7244

Análise

O aumento do **AUC-ROC** indica maior capacidade de distinguir corretamente situações de conflito e sobrevivência no jogo.

CONSIDERAÇÕES FINAIS

Comparação entre os modelos e limitações identificadas no dataset

⚖️ Comparação dos Modelos

Regressão Logística

0.7061

Bom equilíbrio entre interpretabilidade e desempenho geral.

Árvore de Decisão

0.5777

Maior interpretabilidade, porém menor generalização.

Rede Neural

0.7244

Melhor separação entre classes e melhor desempenho geral.

🏆 Melhor Modelo

A **Rede Neural** apresentou o melhor desempenho geral, obtendo maior capacidade de separação entre as classes analisadas.

Melhor AUC-ROC

0.7244

⚠️ Possíveis Limitações



O projeto poderia se beneficiar de maior uso de **feature engineering**, criando variáveis derivadas mais representativas.



A inferência entre **"sucessos"** e **"falhas"** não é perfeita, gerando ambiguidade em parte dos exemplos.



O dataset não possui informações cruciais sobre os conflitos, como **origem da morte**, **número discreto de kills** e contexto detalhado do combate.

💡 Conclusão

Mesmo com resultados competitivos, os modelos ainda possuem limitações relacionadas à qualidade e profundidade do dataset disponível.